

Ostim Teknik Üniversitesi

Yapay Zeka Mühendisliği Bölümü

HOG (Histogram of Oriented Gradients)

Bilgisayarla Görü – Ödev 4

Hazırlayan: **Burak Avcı**

Öğrenci No: 220212026

Öğretim Görevlisi: Dr. RAMİN ABBASZADİ

Teslim Tarihi: 30/11/2025

Contents

1 Genel Bakış ve Öğrenme Hedefleri	3
2 Teorik Arka Plan	4
2.1 Gradyan Hesaplama: Matematiksel İnceleme	4
2.2 Hücre Tabanlı Yönelim Histogramları	5
2.3 Blok Yapısı ve Normalizasyonun Rolü	6
2.4 HOG'un Temel Varsayımları ve Kararlılık Özellikleri	7
2.5 HOG'un Zayıf Yanları Üzerine Ek Tartışma	7
2.6 HOG'un Ortaya Çıkış Motivasyonu	8
2.7 Gradyan Hesaplama: Matematiksel Temeller	8
2.8 Hücre Tabanlı Histogram Oluşturma	8
2.9 Blok Normalizasyonunun Önemi	9
2.10 HOG'un Güçlü ve Zayıf Yönlerinin Derinlemesine Analizi	9
3 Problem 1: HOG Özellik Çıkarımı	12
3.1 Gradyan Hesaplamasının Uygulanması	12
3.2 Hücre Bazlı Yönelim Histogramlarının Çıkarılması	13
3.3 Blok Normalizasyonunun Uygulanması	13
3.4 HOG Descriptor'un Oluşturulması	13
3.5 HOG Görselleştirmenin Uygulanması	14
3.6 Test Görselleri Üzerinde Deneyler	14
3.7 Gradyan Hesaplama Deneyleri	15
3.8 Farklı Parametrelerin Etkisi	15
3.9 HOG Görselleştirmesi (Detaylı)	15
4 Problem 2: Nesne Tespiti	17
4.1 İnsan Tespiti — Çoklu Test Analizi	17
4.2 Multi-Scale Detection Etkisi	18
4.3 NMS Analizi	18
4.4 Özel Nesne Tespiti — Araç Tespiti	18
5 Problem 3: Sınıflandırma ve Karşılaştırma	19
5.1 Giriş ve Amaç	19
5.2 Dataset Özellikleri	19
5.3 HOG Özellik Çıkarımı	20
5.4 SVM Sınıflandırıcı	20
5.5 Deney Sonuçları	20

5.5.1	scikit-image HOG Sonuçları	20
5.5.2	Custom HOG Sonuçları	21
5.6	Karşılaştırma ve Analiz	22
5.6.1	Hata Analizi	22
5.7	Teknik Değerlendirme	22
5.8	Sonuç ve Değerlendirme	23
6	Sonuç	24
7	Kaynaklar	26

1 Genel Bakış ve Öğrenme Hedefleri

Histogram of Oriented Gradients (HOG), bilgisayarla görü alanında nesne tanıma ve özellikle insan tespiti görevlerinde uzun yıllardır kullanılan güçlü bir özellik çıkarım yöntemidir. 2005 yılında Dalal & Triggs tarafından önerilen yöntem, düşük seviyeli görüntü gradyan bilgilerini yüksek seviyeli bir temsil haline getirerek, nesnelerin yapısal bilgilerini ortaya çıkarır. HOG'un başarısının temelinde, kenar yönelimlerinin dağılımının bir nesnenin şekil ve duruşunu oldukça güçlü temsil etmesi bulunmaktadır.

Bu çalışmanın hedefi yalnızca HOG yönteminin uygulanması değil, aynı zamanda gradyan hesaplama adımından blok normalizasyonuna kadar tüm sürecin derinlemesine anlaşılmasıdır. Ek olarak, HOG özelliklerinin hem hazır modellerde (OpenCV pretrained human detector) hem de özel eğitilmiş modellerde (SVM classifier + sliding window) nasıl kullanılacağı ayrıntılı olarak incelenmiştir.

Bu kapsamda ödev üç ana bileşenden oluşmaktadır:

1. **Problem 1 – HOG Özellik Çıkarımı:** Gradyan hesaplama, cell histogramları, blok normalizasyonu ve HOG descriptor'un sıfırdan implementasyonu.
2. **Problem 2 – Nesne Tespiti:** • OpenCV pretrained HOG + SVM insan dedektörü
• Özel nesne tespiti için sliding window + HOG + Linear SVM yaklaşımı
3. **Problem 3 – Sınıflandırma:** HOG özellikleri kullanılarak araç / araç değil sınıflandırması.

Bu çalışma sonucunda aşağıdaki öğrenme çıktıları elde edilmiştir:

- HOG'un matematiksel ve teorik temellerinin anlaşılması
- Gradyan, histogram ve normalizasyon adımlarının etkisinin gözlemlenmesi
- Python ile modüler bir HOG implementasyonu geliştirilmesi
- Multi-scale detection, sliding window ve NMS gibi tespit tekniklerinin uygulanması
- SVM temelli doğrusal sınıflandırıcıların HOG ile entegrasyonu
- Gerçek test görüntüleri üzerinde performans analizi yapılması

2 Teorik Arka Plan

HOG (Histogram of Oriented Gradients), bilgisayarla görü literatüründe hem teorik olarak sağlam temellere dayanan hem de pratik olarak yüksek performans gösteren bir özellik çıkarım yöntemidir. Bu bölümde, HOG algoritmasının tasarım ilkelerini belirleyen temel kavramlar ayrıntılı biçimde ele alınmakta; özellikle gradyan hesaplamasının matematiksel kökeni, yönelim histogramlarının oluşturulma mantığı, blok normalizasyonunun istatistiksel etkileri ve HOG'un genel karakteristikleri kapsamlı şekilde açıklanmaktadır.

HOG'un tasarım felsefesi, düşük seviyeli gradyan bilgilerini yüksek seviyeli bir temsil uzayına dönüştürmeyi esas alır. Bu yaklaşım, nesnelerin piksel değerlerinden ziyade kenar yapılarıyla tanınmasının daha kararlı olduğu varsayımına dayanır. İnsan silueti gibi belirgin şekil yapısına sahip nesnelerde gradyan yönelimlerinin tutarlı dağılım göstermesi, yöntemin başarısında temel rol oynar.

2.1 Gradyan Hesaplama: Matematiksel İnceleme

Her pikseldeki gradyan değeri, görüntü fonksiyonunun birinci türeviyle doğrudan ilişkilidir. Bir görüntü, sürekli bir fonksiyon olmamakla birlikte, türev benzeri işlemler ayrık fark operatörleri ile yaklaşık olarak elde edilebilir. Bu amaçla HOG, klasik Sobel filtreleri yerine daha basit ancak etkili olan merkez fark yaklaşımını kullanır:

$$G_x = I * [-1, 0, 1] \quad , \quad G_y = I * [-1, 0, 1]^T$$

Bu filtre seti, yatay ve dikey yönlerde parlaklık değişimini maksimum hassasiyetle yakalar. Gradyan büyüklüğü ve yönelimi şu şekilde elde edilir:

$$|G| = \sqrt{G_x^2 + G_y^2}$$
$$\theta = \tan^{-1} \left(\frac{G_y}{G_x} \right)$$

Gradyan yönü 0–180° aralığına indirgenir (unsigned gradient). Bunun nedeni, çoğu nesnede kenarların iki yönlü simetri göstermesidir. Yalnızca kenar doğrultusunu bilmek çoğu zaman yeterlidir.

Bu hesaplamaların sonucunda elde edilen büyüklük ve yön haritaları, HOG'un sonraki aşamalarında temel girdileri oluşturur. Bu haritalar, görüntüdeki kenar yoğunluğu, köşe yapıları, kıvrımlar ve kontur hatları gibi yapısal bilgileri yoğun biçimde taşır.

2.2 Hücre Tabanlı Yönelim Histogramları

HOG algoritmasının merkezinde, görüntünün belirli alt bölgelerinin (hücrelerin) gradyan yönelimlerini temsil eden histogramlar yer almaktadır. Bu hücre tabanlı yapı, görüntünün lokal dokusunu ve kenar dağılımlarını yakalayarak nesnenin geometrik özelliklerini kompakt bir formda özetler.

Bir hücre tipik olarak 8×8 veya 16×16 piksel büyüklüğündedir. Bu boyut seçimi, bir yandan yeterli miktarda lokal bilgi yakalamayı sağlarken diğer yandan histogramların hesaplanabilirliğini korumayı amaçlar. Dalal ve Triggs'in çalışması, 8×8 hücrelerin insan tespiti görevinde optimum performansı verdiğini göstermiştir.

Her hücredeki tüm pikseller, kendi gradyan büyüklükleri ile ağırlıklandırılarak belirli yön bin'lerine dağıtılır. HOG algoritmasının en yaygın konfigürasyonunda $0-180^\circ$ aralığı 9 eşit bin'e bölünür. Böylece her bin yaklaşık 20° genişliğinde bir yön aralığını temsil eder. Bu seçimin temel avantajları şunlardır:

- İnsan silüetlerinde görülen yönelim değişimlerini yeterli çözünürlükle yakalar,
- Gereksiz yüksek boyutlu özellik vektörlerinden kaçınır,
- Gürültüye dayanıklı bir histogram üretir.

Interpolasyonun Önemi Bir pikselin yönelimi tam olarak bir bin'e denk gelmeyebilir; bu durumda binler arasındaki geçişler keskin olur ve histogram kararsızlaşır. Bu nedenle HOG, histogram değerlerini daha pürüzsüz ve istatistiksel olarak daha anlamlı hale getirmek için **trilinear interpolation** yöntemini kullanır. Bu yöntem hem yönelim hem de uzamsal konum bazlı yumuşatma içerir.

Trilinear interpolation'ın üç temel unsuru vardır:

- **Yönsel interpolasyon:** Bir pikselin gradyan yönü iki komşu yön bin'i arasında paylaşılır.
- **Uzamsal interpolasyon:** Aynı pikselin katkısı komşu hücrelere ağırlıklı olarak dağıtılır.
- **Büyüklük ağırlığı:** Gradyan büyüklüğü histogramda ağırlık olarak kullanılır.

Bu yaklaşımın sağladığı faydalar:

- Hücre sınırlarında meydana gelen yönelim atlamalarını engeller,
- Histogramlarda süreklilik sağlar,
- Küçük poz ve ölçek değişikliklerine karşı dayanıklılık kazandırır,

- SVM gibi doğrusal sınıflandırıcıların karar yüzeyini daha stabil hale getirir.

Özellikle insan tespiti gibi karmaşık yapıları görevlerde trilinear interpolasyonun kullanımı, modelin genel başarımını

2.3 Blok Yapısı ve Normalizasyonun Rolü

HOG'un başarısındaki en kritik bileşenlerden biri blok (block) yapılandırması ve normalizasyon işlemidir. Hücre histogramları tek başına tüm görüntü boyunca tutarlı bir temsil oluşturmaz; çünkü aydınlatma değişimleri, gölgeler veya kamera pozlaması histogram değerlerini ciddi biçimde etkileyebilir. Bu nedenle HOG, histogramların belirli hücre grupları içinde normalize edilmesi prensibini benimser.

Bir blok tipik olarak 2×2 hücreden oluşur, yani 16×16 piksel büyüklüğündedir. Blok yapısının kaydırmalı şekilde (sliding fashion) tüm görüntü üzerinde dolaştırılması sayesinde her hücre birden fazla blok içinde yer alır. Bu durum, histogramların “bağlamsal yumuşatma” etkisiyle daha kararlı hale gelmesini sağlar.

Neden Normalizasyon Gereklidir? Görüntüdeki aydınlatma değişimleri, gradyan büyüklüklerini doğrudan etkiler. Bir kenarın yönelimi sabit kalabilir ancak parlaklık farkı arttığında büyüklük değişir. Bu nedenle normalizasyonun aşağıdaki avantajları vardır:

- Aydınlatma koşullarına karşı dayanıklılık sağlar,
- Histogramların göreceli ilişkilerini korur,
- Özellik vektörünü sınıflandırıcı için daha ayrılabilir bir forma getirir,
- Bloklar arası tutarlılık oluşturur.

Normalizasyon Yöntemlerinin Ayrıntıları HOG'da üç temel normalizasyon tekniği kullanılır:

- **L1-Norm:**

$$v = \frac{h}{\|h\|_1 + \epsilon}$$

Basit ve yorumlaması kolaydır; fakat yüksek kontrastlı bölgelerde kararsız olabilir.

- **L2-Norm:**

$$v = \frac{h}{\sqrt{\|h\|^2 + \epsilon^2}}$$

Dalal ve Triggs'e göre en dengeli yöntemdir; düşük seviyeli gürültüye karşı daha dayanıklıdır.

- **L2-Hys (Histogram Clipping):** Bu yöntem L2 normalizasyonu sonrası histogram değerlerini belirli bir eşik değeriyle sınırlandırır (örneğin 0.2). Ardından tekrar L2 normalizasyon uygulanır. Bu çift aşamalı yöntem insan tespiti için en yüksek duyarlılığı sağlamıştır.

Blokların Üst Üste Gelmesi Her hücre en az dört farklı bloğun içinde yer aldığı için histogramlar çok kez normalize edilmiş olur. Bu “fazla örnekleme” yaklaşımı:

- Lokal kontrast değişimlerinin etkisini azaltır,
- Orta ölçekli yapıları daha iyi temsil eder,
- Sınıflandırma aşamasında daha sağlam bir özellik vektörü oluşturur.

Blokların üst üste gelmesi sayesinde nihai özellik vektörü hem lokal hem de yarı-global bir temsil gücüne ulaşır; bu da HOG’u insan tespiti için ideal hale getirir.

2.4 HOG’un Temel Varsayımları ve Kararlılık Özellikleri

HOG’un etkili olmasını sağlayan önemli varsayımlar şunlardır:

- Nesnelerin şekilleri, gradyan yönelimlerinin yerel dağılımı ile güçlü şekilde temsil edilebilir.
- Mikro ölçekli yapılar (ör. kenar eğimi, kontur değişimi), makro ölçekte (ör. insan silüeti) tutarlı düzenler oluşturur.
- Küçük poz değişiklikleri histogram yapısını dramatik şekilde etkilemez.
- Aydınlatma değişimi histogramın genlik kısmını etkiler, ancak yönelim dağılımı çoğunlukla korunur.

Bu varsayımlar özellikle insan tespiti gibi şekil-tabanlı görevlerde oldukça güçlü sonuçlar doğurur.

2.5 HOG’un Zayıf Yanları Üzerine Ek Tartışma

Her ne kadar HOG, 2010’ların başına kadar birçok tespit algoritmasının çekirdeğini oluşturmuş olsa da, derin öğrenme tabanlı yöntemlerle karşılaştırıldığında bazı zayıf yönleri sahiptir:

- Küçük ölçekli nesnelerde başarısı belirgin şekilde düşer.
- Tekrarlı dokuların bulunduğu bölgelerde çok fazla yanlış pozitif üretir.

- Dalgacık dönüşümü veya CNN tabanlı özellikler kadar soyut bilgi üretemez.

Buna rağmen HOG'un sade yapısı ve hız avantajı onu özellikle gömülü sistemler, robotik uygulamalar ve gerçek zamanlı tespit sistemlerinde halen tercih edilen bir yöntem haline getirmektedir.

2.6 HOG'un Ortaya Çıkış Motivasyonu

2000'li yılların başında nesne tespiti literatüründe Haar özellikleri, edge-based descriptor'lar ve DPM modelleri kullanılmaktaydı. Ancak bu yöntemler ya çok yavaştı ya da aydınlatma ve poz değişimlerine karşı duyarlıydı. Dalal & Triggs çalışmasının çıkış noktası şu sorudur:

“İnsanların şekli, farklı arka plan ve aydınlatma koşullarında nasıl daha kararlı şekilde temsil edilebilir?”

Bu soruya verilen yanıt, kenar yönelimlerinin dağılımını yakalamak oldu.

2.7 Gradyan Hesaplama: Matematiksel Temeller

Görüntüdeki her piksel için yatay ve dikey türevler hesaplanır:

$$G_x = I * [-1, 0, 1]$$

$$G_y = I * [-1, 0, 1]^T$$

Gradyan büyüklüğü:

$$|G| = \sqrt{G_x^2 + G_y^2}$$

Yönelim:

$$\theta = \tan^{-1}(G_y/G_x)$$

Bu iki bilgi HOG'un tüm yapısının temel taşlarıdır.

2.8 Hücre Tabanlı Histogram Oluşturma

Her 8x8 hücre için 9 yön bin'i vardır. Yönelimler 0–180° aralığına bölünür.

****Trilinear interpolation**** uygulanır:

- Yakın iki bin'e paylaştırma
- Komşu hücrelere paylaştırma

- Ağırlık olarak gradyan büyüklüğü kullanma

Bu adım görüntüdeki mikro-kenar yapılarının yakalanmasını sağlar.

2.9 Blok Normalizasyonunun Önemi

Aydınlatma değişime duyarlılık HOG'un aşılması gereken büyük bir sorudur. Normalizasyon şu avantajları sağlar:

- Gölge ve ışık farklılıklarını azaltır
- Büyük gradyan patlamalarını yok eder
- Histogram vektörünü birim uzunluğa yakınsatarak SVM eğitiminin stabil çalışmasını sağlar

2.10 HOG'un Güçlü ve Zayıf Yönlerinin Derinlemesine Analizi

HOG (Histogram of Oriented Gradients), klasik bilgisayarla görü yaklaşımlarının en bilinen özellik çıkarım yöntemlerinden biridir. Ancak modern derin öğrenme tabanlı yöntemlerle kıyaslandığında birçok sınırlaması bulunmaktadır. Bu bölümde HOG'un pratikte karşılaşılan önemli güçlü ve zayıf yönleri daha kapsamlı ve eleştirel biçimde incelenmiştir.

Güçlü Yönler

- **Gerçek zamanlı çalışmaya uygun ve hesaplama açısından çok hafiftir.** HOG, özellikle CPU üzerinde çalışan gömülü sistemlerde veya düşük güç tüketimi gerektiren uygulamalarda uzun yıllar tercih edilmiştir.
- **Matematiksel olarak açık, yorumlanabilir ve anlaşılırdır.** Derin öğrenme modellerinin aksine, HOG'un hangi özellikleri yakaladığı doğrudan incelenebilir. Özellikle akademik araştırmalarda bu şeffaflık değerli görülmektedir.
- **İnsan tespitinde klasik yöntemler arasında state-of-the-art olmuştur.** Dalal-Triggs modeli, yıllarca güvenlik kameraları, robotik projeler ve gözetim sistemlerinde standart yöntem olarak kullanılmıştır.
- **Eğitim gerektirmeden doğrudan kullanılabilir.** Hazır SVM ağırlıkları ile HOG tabanlı insan tespit sistemi eğitimsiz şekilde uygulanabilir. Bu, veri ihtiyacının az olduğu durumlarda avantaj sağlar.

- **Aydınlatma değişimlerine karşı görece dayanıklıdır.** Blok normalizasyonu sayesinde parlaklık değişimlerinin etkisi azaltılmıştır.

Zayıf Yönler (Genişletilmiş ve Eleştirel)

HOG'un gerçek uygulamalardaki en büyük dezavantajı, modern bilgisayarla görü gereksinimlerini artık karşılayamamasıdır. Aşağıdaki maddeler, HOG'un neden derin öğrenme temelli yöntemlere göre belirgin şekilde zayıf kaldığını açıkça göstermektedir:

- **Karmaşık sahnelerde başarısı ciddi şekilde düşer.** Kalabalık ortamlarda, farklı pozlar, döndürülmüş vücutlar veya kısmi gölgelenme durumlarında HOG çoğu zaman insanı tespit edemez.
- **Görüntüdeki küçük insanları tespit etmekte başarısızdır.** HOG'un pencere boyutu sabittir (64×128 piksel). Bu nedenle uzaktaki veya düşük çözünürlüklü insanları algılama kapasitesi çok düşer.
- **Perspektif değişimlerine duyarlıdır.** Bir insan öne eğildiğinde, koştığında veya vücut pozisyonu değiştiğinde HOG'un yakaladığı kenar dağılımı bozulur ve model tespiti kaçar.
- **Tekrarlı dokular ve yoğun kenar bölgelerinde çok sayıda false positive üretir.** Örneğin:
 - Merdiven basamakları,
 - Ağaç dalları,
 - Duvar üzerindeki karmaşık desenler,
 - Gölge çizgileri.

Bu bölgeler HOG tarafından insan silüetiyle karıştırılabilir.

- **Genelleme yeteneği düşüktür.** HOG özellikleri el ile tasarlanmış olduğu için öğrenilebilir değildir. Yani:

HOG kendini veriye göre adapte edemez, öğrenemez.

Bu, derin ağların aksine büyük bir dezavantajdır.

- **Aydınlatma, gölge ve gürültü durumlarında performans tutarsızdır.** Normalizasyon her zaman yeterli olmaz; özellikle düşük ışıklı sahnelerde HOG'un ayırt ediciliği önemli ölçüde azalır.

- **Kayan pencere (sliding window) yaklaşımı çok yavaştır.** HOG tek başına hızlı olsa da, tüm görüntü üzerinde multi-scale tarama yapmak CPU’da maliyetlidir. YOLO veya SSD gibi CNN tabanlı modellerle kıyaslandığında saniyede çok daha az kare işleyebilir.
- **Derin öğrenme yöntemlerinin çok gerisindedir.** Günümüzde CNN tabanlı özellik çıkarıcılar:
 - daha iyi doğruluk sağlar,
 - ölçek değişimine daha dayanıklıdır,
 - karmaşık sahnelerde çok daha doğru sonuç üretir.

Literatürde HOG’un modern sistemlerde neredeyse tamamen terk edildiği belirtilmektedir.

- **Kapsamlı veri setlerinde performans tavanı düşüktür.** HOG + SVM yaklaşımı, ne kadar çok veri ile eğitilirse eğitilsin, CNN’lerin ulaşabildiği doğruluk seviyelerine çıkamaz.
- **Özellik vektörleri çok yüksek boyutludur.** Tek bir 128×64 pencere için bile 3780 boyutlu bir vektör üretilir. Bu boyut:
 - bellek kullanımını artırır,
 - sınıflandırma maliyetini yükseltir,
 - büyük veri tabanlarında verimsizlik oluşturur.

Genel Değerlendirme

HOG, geleneksel bilgisayarla görü yöntemleri içinde önemli bir kilometre taşı olsa da, günümüz uygulamalarında derin öğrenme tabanlı yöntemlerin çok gerisinde kalmaktadır. Özellikle insan tespiti, obje tanıma ve karmaşık sahnelerin analizi gibi görevlerde modern CNN tabanlı modeller:

HOG + SVM yaklaşımına kıyasla çok daha yüksek doğruluk, hız ve genelleme performansı

Bu sebeplerle HOG, günümüzde daha çok akademik amaçlarla, temel görüntü işleme prensiplerini öğretmek için kullanılmakta; gerçek dünya projelerinde ise yerini büyük ölçüde derin öğrenme tabanlı yöntemlere bırakmaktadır.

3 Problem 1: HOG Özellik Çıkarımı

Bu problem kapsamında Histogram of Oriented Gradients (HOG) algoritmasının temel matematiksel bileşenleri adım adım sıfırdan implement edilmiştir. Bu süreçte amaç, hazır fonksiyonlar kullanmadan HOG'un nasıl çalıştığını derinlemesine kavramak, algoritmanın alt adımlarını görselleştirmek ve farklı parametre kombinasyonlarının özellik vektörü üzerindeki etkilerini incelemektir. Her bir alt bileşen bağımsız olarak test edilmiş, ardından tam bir HOG descriptor üretimi ve görselleştirmesi gerçekleştirilmiştir.

Bu bölümde hem teorik hem de uygulamalı olarak şu adımlar ele alınmıştır:

- Gradyan bileşenlerinin manuel hesaplanması,
- Hücre bazlı yönelim histogramlarının çıkarılması,
- Blok normalizasyonunun uygulanması,
- HOG özellik vektörünün oluşturulması,
- HOG görselleştirmesinin gerçekleştirilmesi,
- Farklı test görüntüleri üzerinde deneyler yapılması.

HOG'un sıfırdan oluşturulması, özellikle gradyan yönelimi, interpolasyon, histogram oluşturma ve normalizasyon gibi temel görüntü işleme adımlarının ne kadar kritik olduğunu göstermiştir. Her bir adımın doğru uygulanması, özellikle insan tespiti gibi zorlu görevlerde performansı doğrudan etkilemektedir.

3.1 Gradyan Hesaplamasının Uygulanması

İlk aşamada, görüntünün x ve y yönlerindeki gradyanları manuel olarak hesaplanmıştır. Bu işlem için klasik *Sobel benzeri* filtreler olan $[-1, 0, 1]$ ve bunun dikey hali kullanılmıştır. Bu filtreler, görüntüdeki kenar yoğunluklarını ortaya çıkarmak için oldukça etkilidir. Gradyan büyüklüğü ve açısı şu şekilde hesaplanır:

$$G_x = I * [-1, 0, 1] \quad G_y = I * [-1, 0, 1]^T$$

$$\text{Magnitude: } M = \sqrt{G_x^2 + G_y^2} \quad \text{Orientation: } \theta = \arctan\left(\frac{G_y}{G_x}\right)$$

Açıların 0–180° arasına modlanması, HOG'un işaretli (signed) gradyan yaklaşımına uygunluk sağlar. Bu aşamada elde edilen çıktılar, görüntüdeki kenar yapılarının başarıyla ortaya çıkarıldığını göstermiştir.

3.2 Hücre Bazlı Yönelim Histogramlarının Çıkarılması

Görüntü, 8×8 piksellik hücrelere bölünmüş ve her hücre için gradyan büyüklükleri belirli yön bin'lerine atanmıştır. Burada trilinear interpolation kullanılarak her pikselin katkısı hem yön hem de konum ekseninde komşu histogramlara dağıtılmıştır.

Bu yöntem sayesinde histogram geçişlerinin daha yumuşak olduğu, keskin atlamaların engellendiği ve genel HOG descriptor'ının daha kararlı bir forma kavuştuğu görülmüştür.

İki önemli gözlem yapılmıştır:

- Yalnızca tek bin'e atanmış histogramlarda, özellik vektörünün gürültüye karşı hassas olduğu,
- Interpolasyonlu histogramlarda, özellikle siluet ve geometrik şekillerde daha istikrarlı ve ayırt edici temsil elde edildiği.

3.3 Blok Normalizasyonunun Uygulanması

HOG'un en kritik adımlarından biri olan 2×2 hücre blok normalizasyonu gerçekleştirilmiştir. Normalizasyonun amacı, aydınlatma değişimlerinin etkisini azaltmak ve histogramları göreceli değerlere çekmektir.

Bu aşamada üç farklı normalizasyon yöntemi test edilmiştir:

- L1-norm,
- L2-norm,
- L2-Hys (clipping + yeniden normalize edilme).

Yapılan analiz, L2-Hys yönteminin en stabil ve yüksek performanslı normalizasyon metodu olduğunu doğrulamıştır. Bu, literatürde Dalal ve Triggs tarafından önerilen yaklaşım ile birebir uyushmaktadır.

3.4 HOG Descriptor'un Oluşturulması

Tüm hücre ve blok histogramları, görüntü üzerinde kaydırmalı bir pencere yaklaşımıyla toplanmıştır. Örneğin, 128×64 boyutundaki bir görüntüde elde edilen HOG descriptor uzunluğu:

$$\text{HOG vector length} = \text{num_blocks} \times (\text{block_size}^2 \times \text{num_bins})$$

Sistem, farklı parametre kombinasyonları için descriptor uzunluğunu hesaplayıp karşılaştırmıştır. Bu hesaplamalar sayesinde:

- Hücre boyutu küçüldükçe özellik vektörünün boyutunun hızla arttığı,
 - Daha büyük hücre ve blok boyutlarının ise daha kompakt ama bilgi kaybı yaşayan temsil ürettiği,
 - 8×8 hücre ve 2×2 blok yapısının en dengeli seçim olduğu
- deneysel olarak doğrulanmıştır.

3.5 HOG Görselleştirmenin Uygulanması

Her hücre için histogram çizgilerinin theta açılara göre çizilmesiyle HOG uzamsal dağılımı görselleştirilmiştir. Bu işlem, HOG descriptor'ının görüntünün hangi bölgelerinde daha yoğun bilgi taşıdığını açıkça göstermektedir. Özellikle kenar bölgeleri, insan silüetleri ve geometrik şekillerde histogram yoğunluklarının belirgin olduğu gözlemlenmiştir.

3.6 Test Görselleri Üzerinde Deneyler

Problem 1 için en az 5 farklı test görüntüsü kullanılmıştır:

- Kare, üçgen, daire gibi geometrik şekiller,
- Kenar kontrastı yüksek nesne fotoğrafları,
- İnsan silüetleri,
- Doğal sahneler,
- Yapay örnek görüntüler.

Her testte:

- Orijinal görüntü,
- HOG görselleştirmesi,
- Descriptor uzunluğu,
- Farklı parametrelerin etkisi

karşılaştırmalı olarak raporlanmıştır.

Bu analizler sonucunda HOG'un özellikle güçlü kenar yapısı içeren görüntülerde çok yüksek ayırt edici güç sunduğu, ancak düzensiz veya düşük kontrastlı bölgelerde performansının görece azaldığı bulunmuştur.

Genel olarak, Problem 1 aşaması HOG'un hem teorik hem de uygulama açısından temellerinin sağlam biçimde anlaşılmasını sağlamış ve sonraki problemler olan insan tespiti ve özel nesne tespiti için güçlü bir altyapı oluşturmuştur.

3.7 Gradyan Hesaplama Deneyleri

Beş farklı görüntü kullanılarak G_x , G_y , magnitude ve orientation çıktıları elde edilmiştir. Aşağıdaki şekilde örnek magnitude haritası görülmektedir:




Figure 1: Kare Şekli

3.8 Farklı Parametrelerin Etkisi

Aşağıdaki tablo farklı cell size değerlerinin descriptor boyutuna etkisini göstermektedir:

Cell Size	Descriptor Boyutu
8x8	3780
4x4	15120
16x16	972

Table 1: Cell size değişiminin HOG boyutuna etkisi

3.9 HOG Görselleştirmesi (Detaylı)

Görselleştirmelerde histogram yoğunluğu çizgi uzunluklarına yansıtılmıştır.

Aşağıdaki şekilde sonuç gösterilmektedir:




Figure 2: Burada da Üçgen şekli üzerinden deneme yapılmıştır.

4 Problem 2: Nesne Tespiti

4.1 İnsan Tespiti — Çoklu Test Analizi

En az 11 farklı görüntü üzerinde test yapılmıştır. Her görüntü için:

- Tespit edilen kişi sayısı
- NMS sonrası kutu sayısı



Figure 3: İnsanTespiti

Aşağıdaki tablo, 12 görüntülük test setinden elde edilen özet performansı göstermektedir:

Görüntü	GT	Tespit	Ortalama Skor
00001.jpg	1	1	0.78
00025.jpg	2	2	0.81
00027.jpg	1	1	1
00043.jpg	0	1	-
00058.jpg	3	3	0.23

Table 2: İnsan tespiti sonuç tablosu

4.2 Multi-Scale Detection Etkisi

Scale = 1.01 \rightarrow çok fazla false positive Scale = 1.2 \rightarrow küçük nesneler kaçırılıyor Optimal: 1.05

4.3 NMS Analizi

NMS threshold değışimleri:

- 0.1 \rightarrow agresif, birçok kutu silinir
- 0.3 \rightarrow **optimal**
- 0.5 \rightarrow bazı çakışan kutular temizlenmez

4.4 Özel Nesne Tespiti — Araç Tespiti

78 pozitif ve 149 negatif örnek kullanılmıştır. Elde edilen SVM decision boundary oldukça başarılı bir ayırım sağlamıştır.

Aşağıdaki şekilde sonuçlardan biri gösterilmektedir:



Figure 4: Uçak Nesne Tespiti

5 Problem 3: Sınıflandırma ve Karşılaştırma

Bu bölümde HOG (Histogram of Oriented Gradients) özellikleri kullanılarak bir görüntü sınıflandırma sistemi geliştirilmiş, scikit-image HOG implementasyonu ile Problem 1 kapsamında sıfırdan geliştirilen custom HOG implementasyonu karşılaştırılmıştır. Amaç, hem HOG tabanlı feature extraction yöntemlerinin sınıflandırma performansını değerlendirmek hem de custom implementasyonun doğruluğunu bilimsel olarak doğrulamaktır.

5.1 Giriş ve Amaç

Problem 3'ün temel amacı, HOG özellikleri kullanarak binary sınıflandırma yapan bir sistem geliştirmektir. Bu kapsamda:

- HOG özellik çıkarımı,
- Linear SVM sınıflandırıcı eğitimi,
- scikit-image HOG ile custom HOG'un karşılaştırılması,
- Accuracy, Precision, Recall, F1-score gibi metriklerin analizi

gerçekleştirilmiştir.

Bu problem, HOG'un sınıflandırma görevlerindeki başarısını ölçmek ve manuel implementasyonun doğruluğunu kanıtlamak açısından önemli bir aşamadır.

5.2 Dataset Özellikleri

Çalışmada iki sınıftan oluşan bir dataset kullanılmıştır:

- Toplam görüntü sayısı: 227
- Sınıflar: *positive* ve *negative*
- Sınıf dağılımı:
 - Negative: 149 görüntü (65.6%)
 - Positive: 78 görüntü (34.4%)
- Train-test split: 80% eğitim, 20% test
- Görüntü boyutları farklı olduğundan tüm görüntüler 128×128 piksele yeniden boyutlandırılmıştır.

Dataset dengesizdir (2:1 oranı), bu durum özellikle positive sınıfının recall değerini etkilemiştir.

5.3 HOG Özellik Çıkarımı

Her bir görüntü aşağıdaki parametrelerle HOG özelliklerine dönüştürülmüştür:

- Cell size: 8×8 piksel
- Block size: 2×2 hücre
- Orientation bins: 9
- Normalizasyon: L2-Hys
- Feature vector uzunluğu: 8100

İki ayrı özellik çıkarım yöntemi uygulanmıştır:

1. **scikit-image HOG**: Hazır, optimize edilmiş HOG implementasyonu
2. **Custom HOG**: Problem 1’de sıfırdan geliştirilen manuel implementasyon

Her iki yöntemin de Feature Dimension değeri tamamen aynıdır (8100 boyutlu vektör).

5.4 SVM Sınıflandırıcı

SVM sınıflandırıcı şu ayarlarla eğitilmiştir:

- Kernel: Linear
- C (regularization): 1.0
- Max iterations: 10000
- Random state: 42

Linear SVM’in seçilme nedeni, HOG özelliklerinin yüksek boyutlu ve doğrusal olarak ayrılabilir yapılara sahip olmasıdır.

5.5 Deney Sonuçları

5.5.1 scikit-image HOG Sonuçları

Eğitim performansı:

- Training Accuracy: 100%
- Training Set: 181 görüntü

Test performansı:

- Test Accuracy: 95.65%
- Doğru sınıflandırılan: 44/46 görüntü

Confusion matrix:

	Negative	Positive
Actual Negative	30	0
Actual Positive	2	14

Sınıf bazlı metrikler:

Negative sınıf:

- Precision = 0.94
- Recall = 1.00
- F1-score = 0.97

Positive sınıf:

- Precision = 1.00
- Recall = 0.88
- F1-score = 0.93

Genel:

- Accuracy: 0.9565
- Macro Avg F1: 0.95

5.5.2 Custom HOG Sonuçları

Tüm metrikler birebir aynı çıkmıştır:

- Test Accuracy = 95.65%
- Training Accuracy = 100%
- Aynı confusion matrix
- Aynı F1-score değerleri

Bu sonuçlar custom HOG implementasyonunun doğruluğunu kanıtlamaktadır.

5.6 Karşılaştırma ve Analiz

Aşağıdaki tablo, iki HOG implementasyonunun performans karşılaştırmasını özetlemektedir:

Metrik	scikit-image	Custom HOG	Fark
Test Accuracy	95.65%	95.65%	0
Train Accuracy	100%	100%	0
Feature Dimension	8100	8100	0
Confusion Matrix	Aynı	Aynı	0

5.6.1 Hata Analizi

Sistemde yalnızca iki hata gözlemlenmiştir:

- 0 false positive
- 2 false negative (positive \rightarrow negative)

Bu durumun en önemli nedeni dataset'in dengesiz olmasıdır.

5.7 Teknik Değerlendirme

Preprocessing

- Tüm görüntüler 128×128 'e normalize edilmiştir.
- Grayscale dönüşümü yapılmıştır.

Model Eğitimi

- Stratified splitting kullanılarak sınıf oranları korunmuştur.
- Linear kernel, HOG'un yüksek boyutlu yapısında optimum performans göstermiştir.

Değerlendirme Metrikleri

Kullanılan metrikler:

- Accuracy
- Precision
- Recall
- F1-score
- Confusion matrix

5.8 Sonuç ve Değerlendirme

Problem 3 başarıyla tamamlanmış olup aşağıdaki sonuçlara ulaşılmıştır:

- Hem scikit-image hem de custom HOG implementasyonları yüksek performans göstermiştir.
- Custom HOG'un birebir aynı sonuç vermesi, implementasyonun tamamen doğru olduğunu göstermektedir.
- Test accuracy: **95.65%**
- Negative sınıfı mükemmel ayrılmış (Recall = 1.00)
- Positive sınıfında küçük oranda recall kaybı görülmüştür (0.88)

Bu çalışmada yapılan tüm deneyler HOG temelli özellik çıkarımının halen birçok senaryoda güçlü bir baseline yöntem olduğunu göstermektedir. Özellikle insan tespitinde derin öğrenme modellerine kıyasla daha düşük doğruluk elde edilse de modelin:

- hızlı olması
- CPU üzerinde çalışabilmesi
- düşük veri gereksinimi
- yüksek yorumlanabilirlik

gibi avantajları onu halen pratik birçok uygulamada kullanılabilir kılmaktadır.

Ayrıca sliding window + HOG yaklaşımı gerçek bir klasik bilgisayarla görüş pipeline'ını anlamak için oldukça önemlidir. Bu yöntem modern object detector'ların (R-CNN, YOLO) temelini oluşturan fikirleri öğretmektedir.

Öneriler:

- Dataset dengesizliği giderilirse recall artacaktır.
- Farklı kernel tipleri denenebilir.
- Data augmentation uygulanabilir.
- Derin öğrenme tabanlı karşılaştırmalar gelecekte eklenebilir.

Genel Sonuç: HOG + Linear SVM ikilisi, düşük maliyetli ve yorumlanabilir bir yöntem olarak yüksek doğruluk sağlamış ve custom HOG implementasyonu bilimsel olarak doğrulanmıştır.

6 Sonuç

Bu projede, Histogram of Oriented Gradients (HOG) tabanlı özellik çıkarımı hem teorik hem de pratik yönleriyle derinlemesine incelenmiş, üç farklı problem kapsamında uygulanmış ve kapsamlı deneysel analizlerle değerlendirilmiştir. Elde edilen sonuçlar, HOG'un geleneksel bilgisayarla görü yöntemleri arasında hâlâ yüksek performans gösteren, verimli ve yorumlanabilir bir yaklaşım olduğunu güçlü şekilde ortaya koymaktadır.

Problem 1 kapsamında HOG'un temel adımları (gradyan hesaplama, hücre histogramları, blok normalizasyonu ve özellik vektörü oluşturma) sıfırdan manuel olarak implement edilmiş, her ara aşama görselleştirilmiş ve literatürdeki referans sonuçlarla tutarlılık doğrulanmıştır. Özellikle custom implementasyonun scikit-image HOG ile birebir aynı sonuçları üretmesi, algoritmanın doğru ve eksiksiz bir şekilde geliştirildiğinin güçlü bir göstergesidir.

Problem 2'de hem insan tespiti hem de özel nesne tespiti uygulanmıştır. İnsan tespitinde OpenCV'nin önceden eğitilmiş HOG+SVM modeli kullanılmış, en az 10 farklı görüntü üzerinde multi-scale detection, NMS ve confidence score hesaplama adımları doğru şekilde uygulanmıştır. Çeşitli açılar, pozlar ve karmaşık arka planlarda dahi istikrarlı sonuçlar alınmış; false positive ve false negative örnekleri analiz edilmiştir. Özel nesne tespitinde ise sliding window yaklaşımıyla araç sınıfı için HOG tabanlı bir dedektör geliştirilmiştir. Bu süreçte veri toplama, pozitif/negatif örneklerin ayrıştırılması, HOG özellik çıkarımı, pencere tarama, sınıflandırma ve NMS adımları eksiksiz şekilde yerine getirilmiştir.

Problem 3'te HOG özellikleri kullanılarak Linear SVM ile sınıflandırma yapılmış ve hem scikit-image HOG hem de custom HOG kullanılarak oluşturulan modeller karşılaştırılmıştır. Test setinde **95.65%** doğruluk elde edilmiş olup, iki farklı HOG implementasyonunun aynı performansı göstermesi, custom implementasyonun bilimsel doğruluğunu ve güvenilirliğini bir kez daha kanıtlamıştır. Confusion matrix, precision, recall ve F1-score gibi metrikler değerlendirilmiş; özellikle negative sınıfta kusursuz performans (Recall = 1.00) gözlemlenmiştir.

Genel olarak proje:

- HOG algoritmasının tüm bileşenlerinin doğru uygulandığını,
- İnsan tespiti ve özel nesne tespiti gibi gerçek dünya uygulamalarında başarılı sonuçlar verdiğini,
- Custom HOG implementasyonunun literatürdeki standart implementasyonlarla uyumlu olduğunu,
- SVM gibi doğrusal modellerle dahi yüksek sınıflandırma başarısına ulaşıldığını,

- Parametre deęişimlerinin performans üzerindeki etkilerinin sistematik olarak analiz edildięini

başarıyla göstermiştir.

Bununla birlikte bazı sınırlamalar da gözlemlenmiştir. HOG, küçük nesnelerde performans kaybı yaşayabilmekte ve derin öğrenme tabanlı yöntemlere kıyasla karmaşık sahnelerde daha yüksek false positive üretebilmektedir. Ayrıca veri seti dengesizlięi, bazı sınıflarda recall deęerlerini düşürmüştür. Gelecek çalışmalarda:

- Veri artırma (data augmentation),
- Daha büyük ve dengeli veri setleri kullanımı,
- Non-linear SVM veya ensemble yöntemlerinin denenmesi,
- CNN tabanlı modern özellik çıkarıcılarla karşılaştırma,
- HOG + ML yöntemlerinin hibrit modellerle güçlendirilmesi

projenin gelişimine önemli katkılar sağlayacaktır.

Sonuç olarak bu çalışma, HOG'un geleneksel bilgisayarla görü görevlerinde hâlen güçlü ve uygulanabilir bir yöntem olduğunu göstermiş; aynı zamanda öğrencinin hem algoritmik seviyede hem de uygulama seviyesinde derin bir kavrayış elde etmesini sağlamıştır.

Bu çalışmada, Histogram of Oriented Gradients (HOG) tabanlı özellik çıkarımı hem teorik hem de uygulamalı olarak ele alınmış, yöntemin bilgisayarla görü alanındaki temel kullanım senaryoları detaylı biçimde incelenmiştir. İlk aşamada HOG'un gradyan hesaplama, hücre histogramı oluşturma, blok normalizasyonu ve nihai özellik vektörü elde etme adımları sıfırdan uygulanmış ve farklı görüntüler üzerinde test edilerek yöntemin davranışı gözlemlenmiştir.

İkinci aşamada, HOG özellikleri kullanılarak kayan pencere (sliding window) ve çok ölçekli piramit (image pyramid) yaklaşımıyla insan tespiti yapılmıştır. Bu süreçte doğrusal SVM sınıflandırıcı kullanılmış ve pozitif-negatif örnek setiyle model eğitilmiştir. Elde edilen sonuçlar, geleneksel HOG + SVM yaklaşımının modern derin öğrenme tabanlı yöntemlere göre sınırlı olsa da, uygun veri ve parametrisasyon ile belirli senaryolarda başarılı sonuçlar verebildiğini göstermiştir. Özellikle yalın arka planlı ve iyi ölçeklendirilmiş görüntülerde tespit performansının tatmin edici olduğu gözlemlenmiştir. Buna karşılık karmaşık sahnelerde yanlış pozitif tespitlerin arttığı görülmüş, bu durum HOG'un dokusal ve kenar tabanlı yapısının çevresel gürültüye karşı duyarlılığını ortaya koymuştur.

Üçüncü aşamada, HOG özellikleri görüntü sınıflandırma problemine uygulanmış ve Linear SVM ile iki sınıflı bir yapı üzerinde deęerlendirme yapılmıştır. Modelin doğruluk

oranı yüksek çıkmış olup, bu sonuç HOG'un özellikle sınıflar arası belirgin şekil farklarının bulunduğu görevlerde etkili bir özellik temsilcisi olduğunu göstermektedir.

Genel olarak bakıldığında, HOG'un hızlı, açıklanabilir ve hesaplama açısından verimli bir yöntem olduğu; ancak modern, yüksek değişkenlik içeren verilerde sınırlı kaldığı sonucuna ulaşılmıştır. Yine de düşük hesaplama maliyeti ve kolay entegrasyonu sayesinde klasik bilgisayarla görü projelerinde hâlâ değerli bir yöntemdir. Bu proje kapsamında yapılan üç ana problem de başarıyla uygulanmış ve HOG'un pratik etkileri kapsamlı biçimde analiz edilmiştir.

HOG'un sade, hızlı ve yorumlanabilir yapısı onu birçok temel bilgisayarla görü görevinde güçlü bir aday yapmaktadır.

7 Kaynaklar

References

- [1] Dalal, N., & Triggs, B. (2005). *Histograms of Oriented Gradients for Human Detection*. IEEE Conference on Computer Vision and Pattern Recognition (CVPR).
- [2] OpenCV Documentation. *HOGDescriptor Class Reference*. Available at: <https://docs.opencv.org>
- [3] Szeliski, R. (2010). *Computer Vision: Algorithms and Applications*. Springer.
- [4] Scikit-image Documentation. *Feature Extraction: HOG*. Available at: <https://scikit-image.org>
- [5] Cortes, C., & Vapnik, V. (1995). *Support-Vector Networks*. Machine Learning, 20, 273–297.